

FalconVerifier 工作总结（2026-09-25）

ChaosButterfly · Hub71 Fish Tank 版。本文供团队内部阅读；对外材料见 docs/talk.html（英文 pitch）与 docs/REPORT_falcon3b_arabic.pdf（学术报告）。代码与全部证据：<https://github.com/hw4375-collab/FalconVerifier>（PR #1）。

1. 我们做了什么（一句话）

FalconVerifier 是一层可审计的中间件：Falcon 用阿拉伯语/英语作答，我们把它的每一步推理（CoT）和最终答案翻译成 Lean 4 命题，交给 Lean 内核证明或否证；被否证的步骤以自然语言反馈给 Falcon 让其修正；整个过程留下机器可验证的 assurance trace。

产品主张（严格版，不夸大）：


- Lean 证明的是"被形式化的那条命题"，不是"Falcon 说的每个字"；
- 落在支持片段之外的句子明确标为 unknown / skipped，系统不装懂；
- "纠错"是"否证"的副产品——即使 Falcon 首轮就对，屏幕上每一步旁边的绿色 verified + 对应 Lean 命题也是有价值的证据（"CoT 可验证率"）。


2. 为什么是阿拉伯语 + Falcon（论证闭环）

- Falcon 是 TII 的本土模型，大量用户用阿拉伯语；
- 预训练数据中阿拉伯语占比小 → 阿拉伯语数学/逻辑推理更弱、更自信地出错（我们的数据：同一批题 3B 阿拉伯语基线 48-58%，7B 97%）；
- 阿拉伯语文本还有放大错误的因素：东/西阿拉伯数字混用、RTL 与数字方向、丰富词形、VSO/SVO 自由语序、«و...ما...أول» 的排他/包含歧义；
- 数学与逻辑的真值与语言无关——一旦译成 Lean 命题，判定权交给内核，绕开了"阿拉伯语数据稀缺"这个瓶颈；
- 阿拉伯语语法高度规则（根-模板形态、固定量词句式 لا أحد / بعض / كل），适合 pregroup 代数语法做确定性（不调 LLM）解析；我们在 Lean 里证明了 VSO ≡ SVO 语义等价，语序归一化是安全的；
- 因此验证 + 反馈把 3B 从 58% 提到 88%（86 题）、48% 提到 76%（245 题），0 回归。

不要说的："阿拉伯语比英语更适合形式化"。正确说法是"形式化对任何语言同样有效，而阿拉伯语在 Falcon 上收益最大（低基线 + 高歧义），且其规则语法让确定性片段可行"。

3. 系统架构（内部构建）





3.1 Python 包 falconverifier/ (约 4.2k 行)

模块	职责
llm.py	Falcon (Open WebUI 兼容 API) 与 OpenAI/OpenRouter 客户端, 统一接口
student.py	学生 Falcon 提示词 (阿/英)、FINAL ANSWER 与步骤抽取
arabic.py	阿拉伯语算术片段: 东西数字归一、百分比/折扣/运算顺序, pregroup 词典 + 解析器 → Lean 命题
arabic_logic.py	量词/条件/析取逻辑片段 (三段论、逆否、非法换位、排他或), 输出一阶命题
arabic_graph.py	对称二元关系与度数/奇偶片段 (握手、朋友), 输出 Regular f k 类命题
formalizer.py	片段路由 → 确定性翻译; 片段外调用 LLM 形式化器, 附 round-trip 忠实性检查 (不一致降 unknown)
lean_runner.py	生成 Lean 文件 (每步一个 example, 正反各试), 按片段选战术 (norm_num/decide/omega/握手引理), 解析错误映射回步骤
verifier.py	组装 VerificationReport, 判定最终答案是否与命题一致
feedback.py	教学反馈模板 (阿/英), 只包含自然语言 + Lean 验证过的等式
agent.py	闭环编排、SSE 事件、assurance_score
bench.py / bench/report.py	基准运行、切片统计、BENCHMARK.md 生成
dpo_export.py	trace → DPO 偏好对 (见 § 6)
server.py	FastAPI: /api/solve、/api/solve/stream、/api/check、/api/bench/*、/healthz、三页静态 UI
cli.py	falconverifier solve/serve/bench/export-dpo

3.2 Lean 项目 lean/ (Lean 4 + Mathlib)

- FalconVerifier/Prelude.lean: 通用引理、 $\mathbb{Q}$ 提升、nlinarith 守卫;
- FalconVerifier/Graph.lean: IsGraph、degree、Regular, 握手引理 $\sum \text{degree} = 2|E|$, 度数上界; 40 组 (n,k) 的存在/不存在定理 (circulant 见证), 五人题 $\forall f : \text{Fin } 5 \rightarrow \text{Fin } 5 \rightarrow \text{Bool}, \neg \text{Regular } f$ 3 18 秒证毕, 无暴力枚举;
- FalconVerifier/Arabic/Pregroup.lean、Semantics.lean、ArabicTypes.lean: 阿拉伯语 pregroup 类型、约化到句子类型的证书、VSO $\equiv$ SVO 语义等价定理、“一致性特征丢失 → 不可导出”定理 (说明粗粒度语法会丢忠实性, 是研究方向)。

3.3 verdict 与 assurance 语义

verdict	含义
verified	Lean 证明了 P
refuted	Lean 证明了 ¬P
unknown	两边都没证出（超时/战术不足/忠实性检查失败）
ill_formed	命题无法类型检查
skipped	不是可检查命题（"我们来计算..."这类叙述句）

assurance_score = $\frac{1}{2} \times$ （最后一轮可检查步骤中 verified 的比例）+ $\frac{1}{2} \times$ （最终答案 verdict 分值：verified 1 / unknown 0.4 / refuted 0）。它不是模型置信度，也不宣称覆盖全部自然语言语义。

4. Benchmark 证据（全部从 bench/results/*/results.json 自动生成）

4.1 主结果：Falcon 自形式化（学生 3B/7B，形式化器 Falcon-H1-Arabic-34B）

run	n	基线	验证后	基线错误	Lean 检出	修正	误报	回归	轮数	时延
3B 阿拉伯语 86 题	86	58.1%	88.4%	36	33 (91.7%)	26	1	0	1.69	39.4 s
3B 阿拉伯语 245 题（扩展）	244	47.9%	76.2%	127	117 (92.1%)	69	1	0	1.86	40.8 s
7B 阿拉伯语 76 题	76	97.4%	98.7%	2	1	1	1	0	1.04	22.9 s
3B 英文 89 题	89	61.8%	78.6%	34	26	—	—	0	—	—
7B 英文 89 题	89	96.6%	98.9%	3	2	—	—	0	—	—

切片亮点（86 题 run）：东阿拉伯数字题 54.8% → 83.9%；确定性片段内题 68.8% → 93.8%，检出率 100%，0 误报。

4.2 CoT 可验证率（新叙事："Lean 逐步审核 Falcon 的思维链"）

run	轮数	步骤数	步骤被判定	verified	refuted	unknown	skipped	最终答案被判定
86 题	145	395	53.2%	49.9%	3.3%	4.6%	42.3%	95.9%
245 题	453	1314	54.6%	50.7%	3.9%	3.4%	41.9%	97.6%

讲法："每一轮 Falcon 输出，Lean 对超过一半的 CoT 句子和 96–98% 的最终答案给出机器证明级判定；其余明确标为不判定而非猜测。"

4.3 诚实修正

生成器曾有 6 题标准答案取整错误（如 150×85%=127.5 被标 128），3B 实际答对却被判错；已排除并修好生成器，DPO 导出因"须匹配标准答案"未受污染。

5. Web UI（评委 5 分钟流程）

三页，ChaosButterfly 白底海军蓝、衬线标题：

- / 验证器（本轮重点优化）
- 顶部 5 步说明 + verdict 图例；
- 示例按钮带 3B 首轮错误率徽章（从 /api/bench/hardness 实时统计所有 3B run，如 3B x 4/4），点阿拉伯语示例自动填英文翻译、标准答案，并自动切到 3B 弱学生；

- 运行中显示已用秒数与 **Stop** 按钮；
- 每轮卡片：Falcon 原文 (RTL) → 逐步 Lean 命题 → verdict 徽章；新增 **CoT 可验证率条** (verified/refuted/unknown/skipped 分段)；refuted 行高亮；"Lean 4 source sent to the kernel (audit)" 折叠面板展示真实送入内核的文件；
- 教学反馈原文 (RTL)；
- 结果 KPI：状态 + 一句话故事 ("round 1 refuted → taught → round 2 verified")、最终答案、assurance、**全程被 Lean 判定的命题数**、轮数/时间、download trace (完整 JSON)；
- **"No time to wait? Replay a recorded correction"**：从已提交 benchmark trace 里挑 6 道 3B 首轮错 → Lean 抓到 → 修正的题 (3 数学 + 3 逻辑)，一键回放，零模型调用——现场不必赌 3B 会犯错。
- **/benchmark**：基线 vs 验证后柱状图、8 个 run 的切片表、逐题展开 (金标/基线/最终/Lean 判定)，每题、results.json、trace、题库、判分代码都链接到 GitHub；"view" 在验证器里回放。
- **/about**：闭环、verdict 语义、为什么阿拉伯语、pregroup、五人题示例、局限。

6. 方向 3: Lean 反馈数据飞轮 (DPO 导出)

falconverifier export-dpo 把 trace 转成偏好对: prompt / rejected (被 Lean 否证的早轮回答) / chosen (后轮、Lean 验证且与金标一致) / evidence (否定命题、内核诊断、反馈)。规则: unknown 不算 rejected; 不使用任何 LLM 裁判; 去重 (prompt, rejected); 保留语言与轮次元数据。

当前 data/dpo_pairs.jsonl: **294 对 (226 阿 / 68 英)**，来自 1038 条 trace，33 重复被丢弃。下一步 (需 ≥24 GB GPU): 对开源 Falcon-H1-3B 做 LoRA-DPO，用同一 benchmark 只测第 1 轮准确率——若上升即证明"形式化反馈可内化进模型"。caveat: chosen 文本带修订口吻 («النصح:»)，训练前需清洗。

7. 基础设施与部署

- **测试**: 99 个 pytest (含 Lean 集成、页面、证据 API、路径穿越、trace 回放、hardness) + lake build; CI (ruff + pytest) 绿。
- **Docker**: Dockerfile 内含 elan + Mathlib 缓存; .github/workflows/docker.yml 在 main 合并后自动发布 ghcr.io/hw4375-collab/falconverifer:latest。
- **部署**: deploy/docker-compose.yml (Caddy 自动 HTTPS、限流、访问令牌、健康检查)、deploy/install.sh (FV_IMAGE=... bash deploy/install.sh 直接拉镜像, 免现场编译 20 分钟)、docs/DEPLOY.md。唯一卡点: 等服务器/域名凭证。
- **性能**: /api/bench/runs、/api/bench/hardness 按 results.json mtime 缓存 (20 ms → 6 ms); Lean 每轮 4-40 s, Falcon 调用 5-20 s; preview 隧道会额外拖慢交互, 本地/服务器部署无此问题。
- **中间件形态**: curl POST /api/solve 一行接入, 返回 verdict + assurance + 完整 trace, 任何调用 Falcon 的应用都可加验证层。

8. 交付物清单

文件	内容
docs/talk.html / docs/talk.pdf	英文 pitch (阿拉伯语原文 + 英文翻译)
docs/REPORT_falcon3b_arabic.pdf	学术报告 (固定在原 76 题 run)
docs/BENCHMARK.md	全部 run 的自动生成表格与逐题清单
docs/ARABIC.md	为什么阿拉伯语、pregroup、形态学忠实性
docs/DPO.md	数据飞轮规则与 caveats
docs/DEPLOY.md / docs/DEMO.md	上线与演示脚本
data/dpo_pairs.jsonl	294 条带 Lean 证据的偏好对

文件	内容
bench/results/**	8 个 run 的 results.json + 每题 trace
Web UI (/ , /benchmark , /about)	preview 在线；服务器凭证到位后 30–45 分钟上线

9. 局限与下一步

局限 - 只覆盖可判定片段（算术、百分比、量词逻辑、对称关系/计数）；证明题、代数应用题为 unknown。 - LLM 形式化器（34B）在二元关系上会丢结构；确定性片段 + round-trip 检查把它降为 unknown 而非误报，但逐步忠实性仍是弱环。 - 3B 采样导致现场可能首轮就对——用"CoT 可验证率"叙事 + 回放兜底。 - 每题 30–40 s 时延；DPO 内化后可去掉推理时的 Lean 成本（待验证）。

下一步 1. 服务器上线 + 二维码； 2. LoRA-DPO 弱版本证明概念（GPU）； 3. Open WebUI Pipe ("Falcon + Lean Verified"模型选项)； 4. 扩片段：比例/比率、简单代数方程、日期/时间。